Explorarea Algoritmilor Bayesieni

Naive Bayes și TAN Bayes

Mitoceanu Ciprian-Minodor

Noiembrie 2026

1 Introducere

În această lucrare vom explora doi algoritmi bayesieni: Bayes Naiv și Tree Augmented Naive Bayes (TAN).

Am ales un set de date tabular pentru a prezice dacă un cântec va deveni viral, pe baza unor caracteristici muzicale precum energia sau gradul de dansabilitate. Setul de date poate fi explorat la adresa https://www.kaggle.com/datasets/vedauv/what-makes-a-song-go-viral-10000-tracks.

2 Prelucrarea Datelor

Înainte de a efectua calculele necesare algoritmilor bayesieni, am curățat datele și am selectat coloanele care influențează cel mai mult rezultatul, pentru a evita overfitting-ul și a reduce zgomotul din model. Așadar, am calculat informația mutuală, iar după rularea programului am obținut următoarele rezultate:

```
Mutual Information Scores (in bits):
----------------------------------------
streams             : 0.3060 bits
danceability        : 0.1212 bits
acousticness        : 0.1206 bits
energy              : 0.0854 bits
valence             : 0.0314 bits
instrumentalness    : 0.0041 bits
tempo_bpm           : 0.0016 bits
speechiness         : 0.0012 bits
duration_sec        : 0.0011 bits
liveness            : 0.0009 bits
loudness_db         : 0.0008 bits
release_year        : 0.0007 bits
```

Calculul delimitează clar caracteristicile care au cea mai mare influență asupra viralității, evidențiind o diferență majoră între valență (0.314 biți) și acustica instrumentală, care scade la 0.0041 biți.

De asemenea, am ignorat coloana *Streams*, deoarece aceasta este corelată direct cu viralitatea și ar duce la o scurgere de informații, compromițând corectitudinea predicțiilor.

3 Naive Bayes

Pentru algoritmul naiv, am început prin calcularea probabilității *a priori* (prior). Pentru setul nostru de date, aproximativ 80% dintre cântece sunt nevirale și 20% sunt virale. Pe urmă vom calcula media pentru fiecare caracteristică și varianța.

Acum că avem toate datele calculate și stocate, putem face predicții. Deoarece datele noastre sunt continue, am folosit distribuția Gaussiană pentru a observa cum se comportă o anumită caracteristică în funcție de clasa vizată (viral sau neviral).

Pentru a determina clasa prezisă de model, am calculat probabilitatea pentru fiecare clasă, înmulțind probabilitatea *a priori* cu probabilitățile fiecărei caracteristici.

$$\hat{y} = \arg\max_{y} \left(\log P(y) + \sum_{i=1}^{n} \log P(x_i \mid y) \right)$$

Notă: Deoarece lucrăm cu probabilități extrem de mici, le-am logaritmat pentru a evita fenomenul de *floating-point underflow*. Astfel, operația de înmulțire s-a transformat în adunare.

4 TAN Bayes

Deși algoritmul naiv este fiabil, acesta presupune că fiecare caracteristică este independentă de celelalte. În practică, acest lucru este rareori adevărat.

Pentru a construi arborele de dependențe între caracteristici, am calculat informația mutuală condiționată între fiecare pereche.

Am construit un graf complet ponderat, fiecare latură având ca greutate informația mutuală condiționată. Din acesta, am extras arborele de acoperire de cost maxim folosind un algoritm precum Kruskal sau Prim. Ulterior, am ales un nod la întâmplare și am direcționat graful pornind de la acesta.

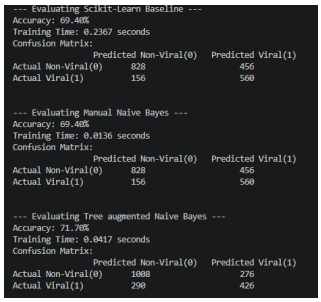
Pentru a calcula probabilitatea ca un cântec să fie viral, am procedat similar ca la algoritmul naiv, însă am inclus și probabilitatea condiționată a fiecărei caracteristici în funcție de părintele său.

Funcția de predicție a clasei devine:

$$\text{Score}(c) = \log P(C = c) + \log P(x_{\text{root}} \mid C = c) + \sum_{i \neq \text{root}} \log P(x_i \mid \pi_{x_i}, C = c)$$

5 Rezultate

Pentru a testa corectitudinea implementării mele, am comparat rezultatele obținute cu cele ale algoritmului Gaussian Naive Bayes din biblioteca *scikit-learn*.



Putem observa că predicțiile ambilor algoritmi naivi sunt identice, însă implementarea propusă de mine rulează de douăzeci de ori mai rapid. Modelul TAN Bayes obține cea mai bună performanță, deși aduce doar un avantaj marginal față de varianta naivă.

6 Concluzie

În concluzie, abordarea bayesiană se dovedește a fi o soluție eficientă pentru predicția viralității cântecelor. În timp ce algoritmul Bayes Naiv se remarcă printr-un timp de execuție excelent, modelul TAN capturează mai precis relațiile dintre variabile, oferind un model teoretic mai robust și o ușoară îmbunătățire a acurateței.